



---

FACULTAD DE INGENIERÍA

MAESTRÍA EN EXPLOTACIÓN DE  
DATOS Y GESTIÓN DEL  
CONOCIMIENTO

---

**Plan de Trabajo Final**

**Diseño de una Arquitectura Multi-RAG  
Multimodal con Orquestación Reflexiva para  
la Gestión del Conocimiento en Dominios de  
Alta Complejidad: Aplicación en el Ámbito  
Corporativo**

**Versión 02**

**Alumno: Lucas Brusasca**

**Director de Tesis: Hernán Merlino**

**Fecha: 23/02/2026**

## Resumen

En el contexto organizacional actual, la toma de decisiones estratégicas depende de la capacidad para procesar volúmenes masivos de información heterogénea. Si bien este trabajo valida su propuesta en los dominios críticos de Impositivo, Financiero, Contable y Legal, la problemática de fondo es transversal a cualquier entorno de alta complejidad: la fragmentación del conocimiento. Las implementaciones tradicionales de RAG monolítico fallan al consolidar datos dispares en un único espacio vectorial, provocando colisiones semánticas que inducen a la "entrega cognitiva" (cognitive surrender), un estado donde el usuario acepta resultados del sistema con escrutinio mínimo, anulando la deliberación crítica. Frente a este desafío, se propone el diseño de una Arquitectura Multi-RAG Multimodal con Orquestación Reflexiva. Esta solución plantea un enfoque modular agnóstico al dominio, actuando como un Sistema 3 (cognición artificial) externo que no solo recupera datos, sino que gestiona la interacción con el usuario mediante un Orquestador con Control de Confianza. Este componente interpreta la intención de la consulta y, ante la detección de incertidumbre, activa una Ruta Reflexiva que mitiga la entrega ciega y fomenta una descarga cognitiva estratégica (cognitive offloading). El resultado esperado es una mejora sustancial en la precisión y trazabilidad del conocimiento, fundamentada en un diseño de alta escalabilidad que permite la integración prospectiva de nuevas unidades de recuperación (n+1) sin alterar el núcleo del sistema, restituyendo la autonomía epistémica en la toma de decisiones corporativas

## Palabras claves

Generación Aumentada por Recuperación (RAG); Orquestación Reflexiva; Sistemas Multimodales; Gestión del Conocimiento; Inteligencia Artificial Generativa; Sistema 3; Entrega Cognitiva; Descarga Cognitiva Estratégica.

# 1. Problema de investigación

En el actual ecosistema tecnológico empresarial, la implementación de Modelos de Lenguaje (LLMs) potenciados por arquitecturas de Generación Aumentada por Recuperación (RAG) se ha consolidado como el estándar de facto para la interacción con bases de conocimiento privadas (Lewis et al., 2020). Este avance representa la emergencia de lo que Shaw y Nave (2026) denominan Sistema 3 (Cognición Artificial): un agente cognitivo externo, automatizado y basado en datos que opera fuera de los límites biológicos de la mente humana. No obstante, la arquitectura predominante presenta una limitación estructural crítica al escalar hacia organizaciones de alta complejidad: la dependencia de un enfoque "monolítico" para la gestión del índice vectorial. Este modelo intenta consolidar la totalidad del acervo documental — abarcando dominios dispares como el financiero, contable, legal e impositivo— en un único espacio vectorial indiscriminado. Si bien esta estrategia resulta funcional para corpus homogéneos, se torna ineficaz en entornos heterogéneos donde la terminología técnica es polisémica y su interpretación depende del contexto normativo (Gao et al., 2024).

Desde una perspectiva técnica, el núcleo del problema radica en la "colisión semántica". Dado que los modelos de embeddings genéricos agrupan vectores basándose en similitudes léxicas superficiales, una consulta sobre un término como "retención" activará vectores provenientes de normativas fiscales, registros contables y contratos legales simultáneamente, sin distinguir su jerarquía. Este fenómeno no solo contamina el contexto enviado al LLM (W. Wu et al., 2025), sino que exacerba un riesgo epistémico fundamental identificado en la literatura reciente: la Entrega Cognitiva (cognitive surrender). Bajo este estado, el experto humano tiende a adoptar las salidas del Sistema 3 con un escrutinio mínimo, abdicando de su capacidad de evaluación crítica y sustituyendo el juicio propio por el de la máquina (Shaw & Nave, 2026).

Este comportamiento se vincula con el marco de la psicología cognitiva de Daniel Kahneman (2011). Los sistemas RAG monolíticos operan bajo la lógica de lo que Kahneman define como el "Sistema 1": un modo de pensamiento rápido e instintivo que salta a conclusiones basadas en patrones estadísticos, pero que al integrarse como un Sistema 3 "en piloto automático", puede cortocircuitar el Sistema 2 (deliberación lenta) del analista (Shaw & Nave, 2026). El resultado es un usuario que, impulsado por una falsa sensación de fluidez y una confianza inflada por la IA, acepta alucinaciones inducidas por recuperación como verdades fácticas (Asai et al., 2023). En consecuencia, la pérdida de trazabilidad fáctica obliga a las organizaciones a realizar validaciones manuales redundantes, generando un riesgo de desprofesionalización (deskilling) por la deferencia repetida a recomendaciones algorítmicas sin un mecanismo ejecutivo de atención selectiva.

Este riesgo de desprofesionalización no es meramente especulativo; investigaciones recientes (Shen & Tamkin, 2026) han cuantificado una caída del 17% en la retención de conocimientos en tareas técnicas cuando la asistencia de la IA elimina la fricción necesaria para el aprendizaje profundo, generando una 'brecha de debugging' donde el experto pierde la capacidad de entender la causalidad de los fallos.

Frente a esta limitación, la arquitectura propuesta implementa un Orquestador con Control de Confianza diseñado para actuar como un monitor de conflicto e incertidumbre. Este componente busca transformar la entrega ciega en una Descarga

Cognitiva Estratégica (strategic cognitive offloading), donde la delegación de tareas al Sistema 3 sea supervisada y evaluada (Shaw & Nave, 2026). La transición a una Ruta Reflexiva se gatilla mediante métricas operacionales de entropía de Shannon ( $H(p) > h$ ) o un margen de confianza estrecho entre dominios, forzando la reactivación del procesamiento deliberativo (Sistema 2) cuando la IA detecta su propia ambigüedad semántica.

Adicionalmente, esta problemática se ve severamente exacerbada por la dificultad de los sistemas RAG tradicionales para procesar la multimodalidad inherente a la documentación corporativa. Una porción mayoritaria del conocimiento estratégico reside en estructuras no textuales complejas, tales como balances, gráficos de rendimiento y formularios. Los procesos de ingestión estándar tienden a "linearizar" estos documentos a texto plano, destruyendo la Integridad Topológica y las relaciones espaciales y numéricas que dan sentido a los datos (Sarathi et al., 2024). Esta fragmentación estructural impide la automatización confiable de consultas complejas, erosionando la confianza del usuario experto y anulando el retorno de inversión esperado al mantener elevados los costos operativos de supervisión (S. Wu et al., 2024; Tonmoy et al., 2024). La magnitud del problema escala con la aceleración digital, donde el fenómeno *lost in the middle* (N. F. Liu et al., 2023) convierte la gestión del conocimiento en un riesgo estratégico sistémico que erosiona la autonomía y la responsabilidad epistémica del profesional (Singh et al., 2025).

En consecuencia, la implementación de un Sistema Multi-RAG con Orquestación Reflexiva se plantea como una solución estructural inspirada en el concepto del "Intérprete" de Michael Gazzaniga (2015): un orquestador capaz de discernir la naturaleza de la consulta y enrutarla dinámicamente al módulo experto que posea la ontología correcta. Este cambio de paradigma transiciona de un modelo reactivo de "búsqueda y recolección" a uno proactivo de "validación y análisis experto". La innovación de este trabajo reside en la transición hacia una arquitectura modular, multimodal e interoperable mediante el protocolo MCP (Model Context Protocol). Este enfoque introduce la Especialización Semántica mediante la segregación de índices expertos para evitar la contaminación cruzada; una Orquestación Reflexiva capaz de utilizar procesos de autorreflexión y Veto Epistémico para validar la consistencia fáctica; y finalmente, una Integridad Multimodal que asegura el tratamiento nativo de formatos complejos mediante ingestión jerárquica (RAPTOR/Docling) y Visión Nativa (vía ColPali), resolviendo definitivamente la "ceguera" tradicional ante datos estructurados (Sarathi et al., 2024; Sun et al., 2024).

## 2. Solución al Problema Identificado

La solución propuesta consiste en el diseño arquitectónico, desarrollo e implementación integral de una Arquitectura Multi-RAG Multimodal con Orquestación Reflexiva, una estructura avanzada y agnóstica al dominio destinada a superar las limitaciones estructurales de los enfoques monolíticos tradicionales en la gestión del conocimiento corporativo de alta complejidad. Estructuralmente, el sistema abandona el paradigma del índice vectorial único e indiscriminado para adoptar una topología distribuida, organizando el acervo documental de la empresa en módulos de recuperación (RAG) especializados y estancos, segregados rigurosamente por dominio de conocimiento: Financiero, Contable, Legal e Impositivo. Cada módulo opera como un "silo experto" que dispone de su propia base vectorial y, críticamente, de un modelo de embeddings ajustado específicamente a la terminología y ontología de su área, lo que permite realizar búsquedas en espacios semánticos diferenciados. Esta segregación elimina de raíz la contaminación cruzada y la "colisión semántica" que afecta a los sistemas generalistas, donde términos polisémicos generan vectores ambiguos que degradan la precisión de la recuperación.

La integración de estos componentes se instrumenta mediante el protocolo estándar MCP (Model Context Protocol) (Anthropic, 2024), configurando cada módulo como un servidor independiente que expone skills (habilidades) o herramientas cognitivas específicas al orquestador. Apoyándose en el paradigma de uso de herramientas por parte de modelos de lenguaje (Schick et al., 2023), el sistema permite que el agente central aprenda a invocar dinámicamente estos skills para resolver la consulta. Esto garantiza la escalabilidad del sistema hacia nuevos verticales de negocio sin alterar la lógica central de control, permitiendo que cada silo evolucione independientemente (Lewis et al., 2020; Gao et al., 2024).

El componente central y diferenciador de esta arquitectura es el "Orquestador con Control de Confianza Cognitivo", un modelo de lenguaje avanzado que actúa como capa de control superior o función ejecutiva. Desde la perspectiva teórica de la Tri-System Theory propuesta por Shaw y Nave (2026), este orquestador no funciona meramente como un buscador, sino que se constituye como un Sistema 3 (Cognición Artificial) externo al usuario. A diferencia de un chatbot estándar que intenta responder directamente mediante asociación estadística, este orquestador analiza la intención profunda de la consulta del usuario, planifica la estrategia de resolución y enruta la petición exclusivamente hacia los módulos expertos pertinentes (por ejemplo, derivando una consulta técnica sobre "retenciones" al módulo fiscal y no al financiero). Para mitigar el riesgo crítico de errores de enrutamiento (routing errors) en consultas ambiguas, el orquestador implementa un modelo de procesamiento de Doble Ruta: ante cada consulta, el sistema evalúa la entropía de la distribución de intenciones ( $H(p)$ ) y el margen de confianza entre los dominios más probables ( $\Delta p < \tau$ ); si se detecta una "Zona Gris" de ambigüedad, el sistema bloquea la inferencia directa y activa una Ruta Reflexiva que descompone la pregunta en sub-tareas y solicita aclaraciones, alineándose con el paradigma de Modular RAG para garantizar la precisión en dominios críticos (Singh et al., 2025). Este diseño busca restaurar la fricción cognitiva necesaria para la consolidación de la memoria, mitigando la caída del 17% en la retención de conocimientos que ocurre cuando el usuario depende acríticamente de la IA.

Adicionalmente, la solución incorpora capacidades de Procesamiento Multimodal Nativo para abordar la integridad de la información, respondiendo al desafío de

procesar evidencia empresarial que reside en formatos no textuales. Dado que una porción mayoritaria de la evidencia crítica se encuentra en balances y reportes financieros, el sistema integra técnicas de comprensión documental jerárquica —como el modelo RAPTOR (Recursive Abstractive Processing for Tree-Organized Retrieval)— para ingerir y vectorizar tablas financieras, gráficos y documentos escaneados preservando su estructura espacial y relacional. Para mitigar los riesgos de alucinación visual inherentes al OCR y asegurar la integridad de los datos, el pipeline de ingestión utiliza Parsing Estructural (vía Docling) complementado con una capa de validación mediante checksums matemáticos, verificando la consistencia aritmética de totales y subtotales recuperados frente al documento original. Esto permite que los datos contenidos en hojas de cálculo complejas sean recuperables con la misma efectividad que el texto plano, superando la "ceguera" de los modelos tradicionales ante datos estructurados (Sarathi et al., 2024; Sun et al., 2024).

Bajo esta lógica, la propuesta se enmarca decididamente en la tendencia de la IA Agéntica (Agentic AI). El sistema trasciende el rol de buscador pasivo para operar como un agente autónomo capaz de utilizar herramientas, validar sus propias respuestas mediante citas cruzadas y solicitar aclaraciones si la consulta es ambigua. Por consiguiente, la solución transforma el repositorio documental de la empresa en un activo dinámico, garantizando que la información recuperada sea no solo semánticamente relevante, sino también trazable y verificable mediante un Metadata Ledger. Esta transparencia permite cerrar la 'brecha de debugging', asegurando que el experto supervise al Sistema 3 en lugar de rendirse ante él. Este enfoque está diseñado específicamente para mitigar el riesgo de Entrega Cognitiva (Cognitive Surrender), asegurando que la IA actúe como un soporte para el juicio experto y no como un reemplazo opaco que induzca a la complacencia intelectual, aplicando un Veto Epistémico activo si la evidencia recuperada es insuficiente para sostener una afirmación fáctica (W. Wu et al., 2025).

Desde el punto de vista operativo, la solución resuelve la problemática central mediante un cambio de paradigma arquitectónico, transicionando de una recuperación "monolítica y pasiva" a una "modular, multimodal y activa". La arquitectura Multi-RAG aborda directamente la colisión semántica mediante la segregación estricta de los espacios vectoriales. Al aislar los dominios en índices independientes, se elimina la posibilidad de que una consulta recupere contextos irrelevantes por mera similitud léxica superficial. Por ejemplo, una búsqueda sobre el término "activos" en el módulo contable no se verá contaminada por definiciones de "activos" provenientes de contratos legales, garantizando que el LLM reciba únicamente información pertinente y depurada. Esta especialización del índice ha demostrado en la literatura técnica reducir significativamente la tasa de alucinaciones y el ruido contextual en comparación con los enfoques unificados. A su vez, la incorporación del Orquestador Cognitivo resuelve la incapacidad de los sistemas tradicionales para interpretar la intencionalidad compleja del usuario experto, permitiendo gestionar consultas transversales que requieren descomponer la pregunta en sub-tareas y consolidar respuestas finales, alineándose con los avances en Agentic RAG donde el sistema planifica su estrategia antes de ejecutarla.

No obstante, la implementación de una arquitectura de esta naturaleza conlleva desafíos operacionales significativos que deben ser gestionados para asegurar su viabilidad. La limitación más crítica radica en la dependencia absoluta de la calidad y actualización del corpus documental, bajo el principio de Garbage In, Garbage Out. Si los documentos base contienen información desactualizada, el sistema recuperará

respuestas erróneas con total confianza, por lo que la eficacia del orquestador está subordinada a políticas estrictas de gobernanza de datos. Asimismo, la arquitectura introduce una complejidad superior asociada a la Latencia y el Costo Computacional derivados de la inferencia secuencial del agente. A diferencia de una búsqueda directa, la intervención de un orquestador que razona y planifica introduce una sobrecarga de tiempo (latency overhead). Para mitigar este impacto y asegurar la escalabilidad económica, la arquitectura propone la integración de un Caché Semántico para resolver consultas recurrentes con latencia cero (sin invocar al modelo generativo), sumado a la implementación de una estrategia de Tiering de Modelos (Jerarquización Dinámica): utilizar Small Language Models (SLMs) de alta velocidad para el ruteo heurístico y consultas fácticas, reservando modelos de razonamiento en tiempo de inferencia (test-time compute) únicamente para la síntesis final de respuestas críticas y la resolución de zonas grises, optimizando así la relación costo-beneficio del sistema (Tonmoy et al., 2024).

### 3. Aplicaciones prácticas

La utilidad principal de la solución propuesta radica en la transformación radical de la capacidad de recuperación y explotación del conocimiento corporativo, mitigando las ineficiencias inherentes a los sistemas de búsqueda tradicionales y los riesgos de alucinación de los LLMs genéricos. En términos operativos, se espera que la implementación del sistema Multi-RAG con Orquestación Reflexiva reduzca drásticamente el "tiempo de acceso a la información" (time-to-information) para los analistas de negocio. Al delegar la tarea de búsqueda y síntesis a un orquestador con Control de Confianza Cognitivo que asume el rol funcional de un Sistema 3 o cognición artificial externa (Shaw & Nave, 2026), capaz de navegar autónomamente por dominios especializados como el Legal, Financiero, Impositivo y Contable, la organización puede liberar miles de horas-hombre actualmente dedicadas a la recolección manual de datos dispersos. Esto facilita una descarga cognitiva estratégica, redirigiendo ese esfuerzo humano hacia tareas de análisis estratégico y toma de decisiones de alto nivel, evitando la fatiga y el sesgo de la entrega cognitiva o abdicación del juicio crítico ante la máquina (Lewis et al., 2020; Singh et al., 2025). Al incentivar la reactivación del Sistema 2, la solución previene la degradación del expertise técnico, mitigando el riesgo de una caída en la retención de conocimientos que estudios recientes sitúan en un 17% bajo modelos de asistencia pasiva (Shen & Tamkin, 2026; Alanazi et al., 2025).

Desde una perspectiva de calidad y gobernanza, la utilidad del sistema se manifiesta en la maximización de la precisión y la trazabilidad fáctica. A diferencia de los enfoques monolíticos que a menudo entregan respuestas plausibles pero incorrectas al mezclar contextos polisémicos, la arquitectura modular garantiza que cada respuesta generada esté anclada a una fuente documental específica y validada dentro de su dominio correspondiente. Esto proporciona una utilidad crítica para áreas de cumplimiento y auditoría, ya que el sistema no solo entrega una respuesta, sino que genera una "pista de evidencia" verificable mediante un Metadata Ledger, permitiendo a los usuarios

humanos corroborar el origen exacto del dato —citando, por ejemplo, la cláusula exacta de un contrato o la celda específica de un balance— antes de actuar sobre él (Gao et al., 2024; Tonmoy et al., 2024).

Adicionalmente, la solución ofrece una utilidad estratégica al desbloquear el valor de los activos de información no estructurados. Dado que el sistema incorpora capacidades multimodales para interpretar tablas financieras complejas y documentos escaneados, permite a la organización capitalizar un vasto acervo de conocimiento que anteriormente era "invisible" para los algoritmos de búsqueda convencionales. Esto habilita nuevos casos de uso, como la comparación automatizada de estados financieros históricos o la detección de anomalías en reportes regulatorios, dotando a la empresa de una ventaja competitiva basada en la explotación exhaustiva de sus propios datos (Sun et al., 2024; S. Wu et al., 2024). Por consiguiente, la utilidad de la propuesta trasciende la eficiencia individual para fomentar una estandarización del conocimiento experto. Al centralizar la recuperación a través de módulos especializados ajustados a la ontología de la empresa e interoperables mediante el protocolo MCP (Model Context Protocol), el sistema actúa como una "fuente única de verdad", asegurando que todos los departamentos —independientemente de su ubicación o antigüedad— accedan a la misma interpretación actualizada de las normativas y procedimientos internos, reduciendo la variabilidad en la toma de decisiones operativas (Q. Wu et al., 2023). En lo que respecta al impacto concreto, las aplicaciones prácticas de esta investigación son extensas y transversales, impactando directamente en los procesos críticos de gestión de información en organizaciones complejas. Una de las aplicaciones operativas más inmediatas es la automatización de la Due Diligence Legal y Corporativa. Tradicionalmente, la revisión de contratos y su cotejo con normativas vigentes es un proceso manual y propenso a errores. La solución propuesta permite desplegar un módulo agente especializado que ingesta miles de documentos contractuales y regulatorios, identificando automáticamente cláusulas de riesgo, inconsistencias normativas o desviaciones en los términos de servicio. Al utilizar una arquitectura modular, el sistema puede validar la legalidad de un documento consultando exclusivamente el índice de "Legislación Vigente", asegurando que el análisis se base en la ley actual y no en documentos obsoletos (Sun et al., 2024; W. Wu et al., 2025).

Simultáneamente, la investigación tiene una aplicación directa en el Análisis Financiero y Contable Multimodal. Dado que la solución integra capacidades para interpretar la estructura espacial de hojas de cálculo y balances en PDF, se habilita el desarrollo de asistentes financieros avanzados. Estos agentes asistentes no solo pueden responder preguntas sobre cifras aisladas, como determinar cuál fue el EBITDA del tercer trimestre, sino que pueden realizar comparativas complejas entre diferentes períodos fiscales extrayendo datos directamente de las tablas originales. Esta capacidad para "leer" la estructura tabular y preservar la integridad topológica resuelve una de las mayores limitaciones de los LLMs actuales, permitiendo a los analistas interactuar con sus reportes de manera conversacional y precisa (Sarathi et al., 2024). Asimismo, se destaca su aplicación en Auditoría Interna y Cumplimiento Normativo (Compliance). La capacidad del sistema para generar respuestas con trazabilidad granular, citando la fuente exacta, página y párrafo, lo convierte en una herramienta de soporte forense ideal. Los auditores pueden utilizar el sistema para rastrear el origen de una decisión administrativa o verificar el cumplimiento de procedimientos internos a gran escala, reduciendo significativamente los tiempos de muestreo y revisión documental. El orquestador actúa aquí como un "auditor digital" preliminar, filtrando la información

irrelevante y presentando al experto humano solo la evidencia sustantiva (Gao et al., 2024). Esta trazabilidad granular es fundamental para cerrar la 'brecha de debugging', asegurando que el auditor no solo reciba una respuesta, sino que comprenda la lógica subyacente de la recuperación, manteniendo su capacidad de supervisión crítica sobre el Sistema 3.

Finalmente, la investigación sienta las bases para la creación de Sistemas de Soporte a la Decisión (DSS) Agénticos y Reflexivos. Más allá de la simple búsqueda, la arquitectura propuesta permite implementar flujos de trabajo autónomos donde el sistema puede, por ejemplo, detectar una nueva regulación impositiva desde el Módulo Legal y alertar proactivamente sobre su impacto en los estados contables de la empresa en el Módulo Financiero, demostrando una capacidad de razonamiento cross-dominio que redefine la inteligencia empresarial (Singh et al., 2025).

Bajo este análisis, la propuesta presenta un grado de innovación sustancial y disruptivo, clasificándose como una innovación de arquitectura que integra componentes de vanguardia para redefinir la interacción con el conocimiento corporativo. La solución trasciende el estándar de industria actual —el RAG ingenuo o Naive RAG— para adoptar una arquitectura de Orquestación Reflexiva. Mientras que las implementaciones comerciales típicas se limitan a recuperar fragmentos por similitud vectorial simple, esta propuesta introduce un Orquestador con Control de Confianza Cognitivo que dota al sistema de capacidad de planificación y razonamiento autónomo. Este núcleo opera bajo un modelo de procesamiento de doble ruta para gestionar la ambigüedad semántica: una Ruta Heurística (Sistema 1) basada en un Semantic Router para intenciones de alta confianza, y una Ruta Reflexiva (Sistema 2) que se activa ante la detección de una "Zona Gris". Esta zona se define operacionalmente cuando la entropía de la distribución de ruteo supera un límite predefinido ( $H(p) > h$ ) o cuando el margen de confianza entre los dos dominios más probables es marginal ( $\Delta p < \tau$ ), forzando al orquestador a ejecutar una planificación de sub-tareas, desambiguación de términos y validación de consistencia. Este mecanismo de seguridad se refuerza con un Veto Epistémico basado en métricas de RAGAS que dispara una abstención activa si el score de confianza no alcanza el umbral de seguridad, fomentando una descarga cognitiva estratégica y evitando alucinaciones (Singh et al., 2025; Shaw & Nave, 2026).

A nivel estructural, la innovación reside en la especialización semántica del índice a través de un diseño Multi-RAG. La propuesta rompe con el enfoque monolítico tradicional mediante la implementación de una topología distribuida, donde múltiples bases vectoriales especializadas (Legal, Financiera, Contable, Técnica) coexisten y son consultadas selectivamente según la intención del usuario. Este diseño, validado por estudios recientes, representa un avance significativo en la reducción de ruido contextual y alucinaciones en dominios de alta complejidad. Al evitar la mezcla de terminologías polisémicas en un mismo espacio latente, se logra una precisión que los modelos generalistas no han logrado resolver eficazmente en entornos empresariales cerrados (Gao et al., 2024). Adicionalmente, el proyecto innova en el tratamiento de la multimodalidad nativa aplicada a documentos corporativos. Al integrar técnicas de visión artificial (ColPali) y modelos de lenguaje multimodal para procesar y "entender" la estructura espacial de documentos financieros —como tablas en balances o gráficos de rendimiento— en lugar de convertirlos a texto plano desestructurado, la solución aborda la pérdida de contexto en la digitalización. La exactitud tabular se valida mediante checksums matemáticos que verifican la consistencia aritmética de totales y subtotales recuperados frente al original. Complementariamente, la organización en

un Árbol de Conocimiento (RAPTOR) permite una granularidad de recuperación que resuelve el fenómeno de lost in the middle, adaptándose desde el contexto macro hasta el dato técnico (Sarathi et al., 2024; Sun et al., 2024). Finalmente, para gestionar los desafíos de latencia y costo computacional derivados de la inferencia secuencial, la arquitectura implementa un Tiering de Modelos que selecciona dinámicamente entre Small Language Models (SLM) locales para tareas fácticas y LLMs de alto razonamiento para casos críticos. Este enfoque garantiza la viabilidad económica sin comprometer la capacidad de análisis profundo, transformando al sistema en un analista virtual confiable capaz de justificar sus conclusiones con evidencia trazable (Tonmoy et al., 2024; W. Wu et al., 2025).

## 4. Transferencia de los resultados obtenidos

La ampliación estratégica de esta investigación debe orientarse hacia líneas de desarrollo técnico y funcional que fortalezcan la robustez del sistema para operar en entornos organizacionales de alta complejidad, superando las restricciones inherentes al alcance del prototipo actual y respondiendo a los desafíos críticos de la orquestación en escenarios de incertidumbre. Para abordar la limitación sobre la heterogeneidad y calidad de los datos de entrada, resulta imperativo profundizar en la automatización de los procesos de curaduría documental mediante la integración de agentes autónomos de preprocesamiento que operen bajo el principio de sanitización semántica. Estos módulos no se limitarán a una limpieza superficial, sino que ejecutarán tareas de alta complejidad cognitiva, tales como la corrección contextual de errores de OCR y la desambiguación de entidades nombradas en documentos legales y financieros antes de su vectorización. Esta mejora es fundamental para mitigar el riesgo de errores de enrutamiento (routing errors), ya que un espacio latente depurado reduce las colisiones semánticas que generan las consultas grises o ambiguas. En este sentido, la implementación de la técnica RAFT (Retrieval Augmented Fine-Tuning) se presenta como un paso lógico para entrenar al modelo en la distinción de documentos distractores, forzando al sistema a ignorar información irrelevante y a citar fácticos con precisión matemática (Barnett et al., 2024; Mitra & Craswell, 2018).

En segunda instancia, el enfoque multimodal debe expandirse sustancialmente mediante la incorporación de modelos de Comprensión de Documentos Visuales (VDU) que preserven la integridad topológica de estructuras no lineales, tales como balances contables y gráficos de proyección. La integración de arquitecturas multimodales nativas, especializadas en el razonamiento sobre datos cuantitativos y relaciones espaciales, permitirá al sistema superar la ceguera de los modelos tradicionales ante tablas cruzadas y diagramas de flujo. Sin embargo, esta implementación conlleva riesgos intrínsecos relacionados con la alucinación visual y la pérdida de referencia estructural al linearizar formatos complejos; por lo tanto, el desarrollo futuro debe centrarse en mecanismos de validación cruzada que aseguren que la interpretación de un gráfico sea consistente con la evidencia textual adyacente, ampliando el espectro de consultas resolubles hacia auditorías complejas y análisis de riesgos estratégicos (H. Liu et al., 2023; Sun et al., 2024). Para mitigar la limitación técnica asociada a la latencia de

inferencia y el elevado costo computacional de los flujos de trabajo secuenciales agénticos, se propone investigar la aplicación de técnicas de Destilación de Conocimiento (Knowledge Distillation) y cuantización. Esto implicaría transferir las capacidades de razonamiento del Orquestador con Control de Confianza Cognitivo a Modelos de Lenguaje Pequeños (SLMs) más eficientes, permitiendo un despliegue on-premise económico sin sacrificar la precisión fáctica. La selección dinámica del modelo se basará en la complejidad detectada en la ruta reflexiva: mientras que las consultas fácticas de alta confianza serán resueltas por SLMs de baja latencia, las tareas analíticas de nivel legal o financiero activarán LLMs de alto razonamiento. Asimismo, es crucial cerrar el ciclo de aprendizaje mediante mecanismos de Aprendizaje por Refuerzo a partir de Retroalimentación Humana (RLHF), donde expertos validen las respuestas para que el sistema evolucione hacia una inteligencia adaptativa que refine sus políticas de recuperación y ruteo con el uso continuo (Ouyang et al., 2022; W. Wu et al., 2025).

Más allá del ámbito corporativo, la arquitectura de Sistema Multi-RAG con Orquestación Reflexiva posee una versatilidad que permite su transferibilidad directa a dominios de alta criticidad como el sector de Salud y Biomedicina. En este campo, la medicina enfrenta desafíos de colisión semántica entre protocolos de distintas especialidades (e.g., cardiología vs. neurología) y la necesidad de procesar historias clínicas e imágenes diagnósticas estructuradas. La implementación de un orquestador capaz de segregar estas bases de conocimiento bajo el paradigma del Sistema 3 reduciría el riesgo de alucinaciones en sistemas de soporte a la decisión clínica (CDSS), facultando a los profesionales para recuperar evidencia precisa desde fuentes heterogéneas basada en protocolos vigentes (Sun et al., 2024). Esto asegura que el profesional no se 'rinda' ante la IA (cognitive surrender), preservando su capacidad crítica y deliberativa en diagnósticos donde el error es grave

De igual manera, la Administración Pública y el Gobierno Digital constituyen campos fértiles para esta metodología, permitiendo gestionar múltiples índices y enrutar consultas ciudadanas hacia agentes legislativos o tributarios específicos, mejorando la transparencia y la eficiencia del servicio público al guiar al usuario a través de trámites burocráticos complejos, alineándose con las tendencias globales de Agentic AI (Singh et al., 2025). Finalmente, la investigación aporta un marco de referencia transferible a la Educación Superior y la Industria 4.0. Un tutor inteligente basado en esta arquitectura podría orquestar conocimientos de distintas facultades (Exactas vs. Humanidades) sin mezclar contextos, permitiendo a los estudiantes interactuar con material heterogéneo que incluye fórmulas y gráficos científicos. En el ámbito industrial, la validación de técnicas de curaduría y recuperación granular propuestas ofrece una base metodológica sólida para el desarrollo de asistentes técnicos de alta fiabilidad, capaces de interpretar manuales de despiece y planos CAD en tiempo real para el mantenimiento predictivo, garantizando la trazabilidad fáctica y la seguridad epistémica en entornos de operación crítica (Gao et al., 2024; Barnett et al., 2024). Asimismo, en el ámbito educativo, este diseño evita el uso pasivo de la herramienta, mitigando la caída del 17% en la retención de conocimientos que ocurre cuando no existe un esfuerzo cognitivo por parte del usuario

## 5. Objetivo del trabajo

- Objetivo general

Diseñar una arquitectura de sistema Multi-RAG Multimodal con Orquestación Reflexiva, fundamentada en la Tri-System Theory como un Sistema 3 de cognición artificial externa, destinada a la gestión eficiente del conocimiento en dominios corporativos de alta complejidad, mitigando el riesgo de entrega cognitiva (cognitive surrender) y optimizando la trazabilidad fáctica de la información en comparación con los enfoques monolíticos convencionales.

- Objetivo específico

- ✓ Caracterizar la estructura semántica y ontológica de los dominios Financiero, Legal, Contable e Impositivo, con el fin de definir estrategias de preprocesamiento, chunking adaptativo y modelos de embedding especializados que minimicen la colisión semántica en el espacio latente.
- ✓ Diseñar la arquitectura lógica y funcional del sistema integrando índices vectoriales independientes y un componente de Orquestación Reflexiva con Control de Confianza; este núcleo operará bajo un modelo de doble ruta basado en métricas de entropía de Shannon ( $H(p) > h$ ) y márgenes de confianza ( $\Delta p < \tau$ ) para forzar la reactivación del procesamiento deliberativo (Sistema 2) del experto ante escenarios de alta incertidumbre.
- ✓ Desarrollar un prototipo funcional que implemente capacidades de procesamiento multimodal nativo para la interpretación de documentos complejos, utilizando técnicas de parsing estructural y visión artificial validadas mediante checksums matemáticos para asegurar la integridad topológica de los datos y mitigar alucinaciones visuales.
- ✓ Validar el desempeño del sistema mediante un protocolo experimental contrastado contra baselines de RAG monolítico, evaluando la capacidad de la arquitectura para preservar la autonomía epistémica y la retención de conocimientos del usuario en comparación con asistentes de respuesta directa.

## 6. Trabajos relacionados

La problemática central de esta investigación, focalizada en las limitaciones estructurales de los sistemas de Generación Aumentada por Recuperación (RAG) monolíticos ante dominios de conocimiento heterogéneos y la consecuente necesidad de una Orquestación Reflexiva, ha sido objeto de un análisis exhaustivo y reciente en la literatura científica de vanguardia. La evolución desde arquitecturas estáticas hacia

sistemas dinámicos y modulares marca el estado del arte actual, impulsada no solo por necesidades de escalabilidad computacional, sino por la urgencia de que estas herramientas funcionen como un Sistema 3 de cognición artificial externa (Shaw & Nave, 2026), evitando así la abdicación del juicio crítico del usuario.

En primer lugar, resulta imperativo destacar la contribución de (Gao et al., 2024), quienes en su estudio fundamental sobre la evolución del paradigma introducen el concepto de Modular RAG. Los autores realizan una disección crítica de los sistemas de "Naive RAG", demostrando que estas arquitecturas sufren una degradación severa en la precisión (hallucination rate) cuando se enfrentan a corpus vastos y diversos. Su investigación valida la hipótesis de que la rigidez de un pipeline lineal "Recuperar-Leer" es insuficiente para consultas complejas. En contraposición, proponen una arquitectura desagregada que incorpora módulos de enrutamiento (Routing) y programación (Scheduling), permitiendo que el sistema decida dinámicamente qué componentes activar. Este trabajo constituye la base teórica angular para la presente tesis, ya que justifica técnicamente la transición hacia un diseño donde los módulos de recuperación son especializados y el flujo de información es gestionado por una entidad superior, superando la ineficiencia de los índices vectoriales únicos.

Profundizando en la problemática de la interferencia entre dominios, (W. Wu et al., 2025) abordan directamente el fenómeno de la "colisión semántica" en su desarrollo del marco MultiRAG. Su estudio empírico evidencia que la integración forzada de múltiples fuentes de conocimiento (por ejemplo, bases de datos médicas mezcladas con normativas legales) en un espacio vectorial compartido induce a "alucinaciones por recuperación". Esto ocurre porque la proximidad vectorial no siempre implica relevancia contextual en dominios técnicos disjuntos. La solución que proponen —un marco guiado por el conocimiento (knowledge-guided) que utiliza mecanismos de atención para segregar contextos— se alinea metodológicamente con el objetivo de este proyecto de aislar los dominios financiero, legal, contable e impositivo. Los autores concluyen que la separación lógica de las fuentes es una condición sine qua non para garantizar la trazabilidad y la veracidad de la respuesta en entornos corporativos de misión crítica.

Por otra parte, la evolución hacia sistemas con capacidad de agencia es explorada por (Singh et al., 2025) en su exhaustivo análisis sobre Agentic RAG. Esta investigación marca un cambio de paradigma: desplaza el foco desde la recuperación pasiva de documentos hacia la orquestación activa, donde un componente agente inteligente actúa como mediador proactivo. Singh et al. demuestran que, para consultas que requieren razonamiento multi-salto (multi-hop reasoning), es indispensable contar con un módulo agente que pueda descomponer la pregunta, planificar la búsqueda y seleccionar la herramienta adecuada. Esta perspectiva es crucial para la presente tesis, pues fundamenta la necesidad operativa del "Orquestador con Control de Confianza Cognitivo". No basta con tener índices separados; se requiere una capa de inteligencia que discierna la intención del usuario y ejecute un enrutamiento semántico preciso. A esto, nuestra propuesta añade la necesidad imperiosa de introducir una fricción estratégica en dicha orquestación para mitigar la caída del 17% en la retención de conocimientos que investigaciones recientes asocian a la asistencia algorítmica pasiva.

Finalmente, el trabajo de (Barnett et al., 2024) proporciona un marco de referencia sobre los fallos de ingeniería en estos sistemas. Al identificar los "siete puntos de falla" en RAG, los autores subrayan que los modelos generalistas suelen fallar al procesar documentos altamente técnicos debido a que los espacios vectoriales estándar no logran capturar las sutilezas semánticas de cada área específica (por ejemplo, la

diferencia entre un "activo" en términos contables vs. legales). Esta evidencia respalda la decisión metodológica de este trabajo de aplicar estrategias de preprocesamiento y modelos de embedding diferenciados para cada sector, asegurando que la representación latente de los datos sea fiel a su dominio de origen.

En el marco del desarrollo de una arquitectura Multi-RAG con Orquestación Reflexiva, es fundamental identificar investigaciones que, si bien no proponen un sistema de coordinación idéntico, abordan desafíos técnicos periféricos —pero críticos— para la viabilidad operativa de la solución, tales como la multimodalidad, la calidad de los datos y la mitigación de errores generativos.

Una de las barreras más persistentes en la digitalización de conocimiento empresarial es la denominada "ceguera multimodal", especialmente en la interpretación de estructuras no textuales. Al respecto, (H. Liu et al., 2023), en su trabajo sobre Visual Instruction Tuning (base del modelo LLaVA), analizan cómo los modelos de lenguaje tradicionales fallan sistemáticamente al procesar información financiera cuando esta pierde su topología visual durante la vectorización (por ejemplo, la relación espacial en una tabla de balance). Su investigación propone mecanismos de proyección que permiten al sistema "ver" y "razonar" sobre la disposición espacial de los datos antes de convertirlos en embeddings. Este enfoque es vital para la presente tesis, dado que los documentos contables e impositivos dependen intrínsecamente de su estructura tabular; la integración de capacidades VDU (Visual Document Understanding) derivadas de este trabajo permitirá al sistema interpretar celdas y gráficos con la misma fluidez que el texto narrativo.

Paralelamente, la mitigación de alucinaciones en entornos de múltiples fuentes constituye un desafío de alta relevancia. (Tonmoy et al., 2024) presentan un estudio taxonómico sobre las técnicas de mitigación, distinguiendo entre alucinaciones intrínsecas del modelo y aquellas inducidas por una recuperación defectuosa (hallucination-induced by retrieval). Su análisis demuestra que, en sistemas RAG, la mayoría de los errores provienen de recuperar contexto irrelevante o contradictorio que "confunde" al generador. Este hallazgo es un insumo técnico esencial, ya que justifica la función del Orquestador no solo como un enrutador, sino como un filtro de calidad (re-ranking) que debe validar la coherencia semántica de los fragmentos recuperados antes de enviarlos al LLM, actuando como una barrera de contención contra el ruido informativo.

En cuanto a la especificidad del dominio, (Sun et al., 2024) documentan un caso de estudio sobre RAG para dominios específicos (geográficos y académicos), que ofrece lecciones transferibles al ámbito empresarial. Los autores demuestran que la personalización extrema de los procesos de ingestión —optimizando el tamaño de los chunks y ajustando los parámetros de búsqueda— supera significativamente a las implementaciones generalistas (mejorando métricas de F1-score del 5% al 42% en sus experimentos). Este resultado empírico valida la premisa de segmentar el conocimiento organizacional en silos especializados. Al igual que Sun et al. ajustaron sus recuperadores para un dominio específico, esta tesis propone ajustar los índices vectoriales a la terminología particular de los sectores Legal y Financiero, evitando la dilución semántica que ocurre en los índices únicos.

Asimismo, la importancia de la curaduría de datos previa a la ingestión es explorada por (Mitra & Craswell, 2018). En sus investigaciones fundamentales sobre modelos de recuperación neuronal, enfatizan que la relevancia es una variable que debe optimizarse desde la representación del documento. El uso de representaciones distribuidas para capturar la semántica de documentos largos proporciona un marco

para entender cómo el preprocesamiento de metadatos puede mejorar la trazabilidad. Complementariamente, marcos de evaluación como los discutidos por (Barnett et al., 2024), que proponen métricas de "fidelidad" y "relevancia del contexto", son directamente aplicables para validar la arquitectura propuesta, asegurando que la orquestación se apoye en una base sólida de evaluación cuantitativa.

Históricamente, la identificación de las falencias estructurales en los sistemas de recuperación de información y generación ha sido un proceso evolutivo, intensificado por la adopción masiva de LLMs en flujos de trabajo corporativos complejos. La literatura ha transitado desde el optimismo inicial hacia una crítica fundamentada sobre las limitaciones de escalabilidad y precisión.

Es imperativo remitirse al trabajo fundacional de (Lewis et al., 2020). Al proponer la arquitectura original de Retrieval-Augmented Generation (RAG), los autores ya advertían sobre la extrema sensibilidad del modelo generador ante la calidad del contexto recuperado. Aunque su enfoque fue revolucionario al dotar a los modelos de "memoria no paramétrica", identificaron tempranamente que la "contaminación" del contexto con información irrelevante degradaba la veracidad de las respuestas. Este hallazgo sentó el precedente teórico sobre la necesidad de mecanismos de filtrado y curaduría selectiva, una problemática que los sistemas monolíticos actuales exacerbaban al mezclar indiscriminadamente documentos de diversa índole.

Posteriormente, la investigación profundizó en los síntomas específicos de degradación en grandes corpus. (N. F. Liu et al., 2023) identificaron y formalizaron el fenómeno crítico conocido como "Lost in the Middle". Sus experimentos demostraron empíricamente que los modelos de lenguaje tienden a ignorar o procesar deficientemente la información ubicada en el centro de documentos extensos o de listas largas de pasajes recuperados. Este descubrimiento es un antecedente vital para la problemática de la "colisión semántica" abordada en esta investigación: evidencia que un índice monolítico no solo confunde al modelo por la mezcla de términos, sino que impide físicamente que el sistema "preste atención" a la información relevante si esta queda "enterrada" bajo una masa de vectores de baja afinidad semántica provenientes de otros dominios.

Desde una perspectiva sistémica, (Gao et al., 2024) categorizan formalmente estas limitaciones bajo el concepto de "Naive RAG". Los autores señalan que los problemas de baja precisión (low precision) y la falta de adaptabilidad ante consultas complejas son fallas inherentes a las arquitecturas que carecen de una capa de razonamiento intermedia. De manera complementaria, (Barnett et al., 2024) identificaron que el cuello de botella en entornos de alta especialización técnica no reside exclusivamente en el modelo de lenguaje, sino en la incapacidad de los modelos de embedding generalistas para capturar sutilezas en dominios restringidos. Al detectar que documentos con léxico similar (ej. un contrato vs. una factura) requieren tratamientos lógicos opuestos, estos investigadores validaron la inviabilidad de los sistemas de propósito general para tareas de misión crítica.

Adicionalmente, (W. Wu et al., 2025) han identificado la "alucinación inducida por recuperación" como una consecuencia directa de la interferencia entre múltiples fuentes. Su estudio expone cómo la coexistencia de documentos de dominios heterogéneos dentro de un mismo espacio vectorial genera confusión en los mecanismos de atención del Transformer, derivando en respuestas que mezclan contextos de forma errónea. Finalmente, autores como (Karpukhin et al., 2020), en sus estudios sobre Dense Passage Retrieval (DPR), ya planteaban los desafíos de escalabilidad y la necesidad de fragmentar el conocimiento para mantener la eficiencia

computacional y semántica. La presente investigación retoma estas identificaciones previas y propone la Orquestación Reflexiva como el mecanismo definitivo para resolver la fragmentación y el ruido que estos autores señalaron como barreras insalvables para el RAG tradicional.

En relación con la metodología propuesta en esta investigación, basada en la segmentación modular del conocimiento y la implementación de una capa de orquestación estructurada en módulos expertos, esta se alinea y refina las tendencias más recientes en la ingeniería de sistemas cognitivos complejos. Diversos autores han validado componentes de esta metodología para resolver problemas de naturaleza análoga.

Dentro de este marco metodológico, destaca nuevamente el trabajo de (Singh et al., 2025) sobre Agentic RAG. Estos autores emplean una aproximación casi idéntica a la planteada en esta tesis para resolver problemas de recuperación en entornos dinámicos: en lugar de utilizar un pipeline lineal y estático, implementan procesos de razonamiento autónomo capaces de descomponer preguntas complejas en sub-tareas, planificar la recuperación y utilizar herramientas. Su enfoque valida el diseño arquitectónico del orquestador, demostrando que la introducción de un componente que "razona" (Planificación) antes de "buscar" (Ejecución) incrementa sustancialmente la precisión y permite manejar consultas que los sistemas tradicionales son incapaces de resolver.

Asimismo, la metodología de sistemas multi-agente para la resolución de conflictos de información ha sido aplicada exitosamente por (Q. Wu et al., 2023) en el desarrollo del marco AutoGen. Aunque su enfoque es generalista, la arquitectura subyacente es homóloga a la de esta propuesta: múltiples módulos con roles definidos y bases de conocimiento aisladas colaboran bajo la supervisión de un coordinador para sintetizar una respuesta. Los autores demuestran que la especialización funcional reduce las alucinaciones y mejora la coherencia lógica del resultado final. Esta tesis transfiere dicha metodología al dominio corporativo, asignando a cada módulo experto la responsabilidad de un silo documental.

Por otra parte, la metodología de "Recuperación Correctiva" o Corrective RAG (CRAG), presentada por (Yan et al., 2024), ofrece un paralelismo metodológico significativo. Estos investigadores abordan el problema de la baja calidad en la recuperación mediante un evaluador ligero que juzga la relevancia de los documentos recuperados y decide dinámicamente si es necesario buscar en fuentes externas o refinar la consulta. Esta lógica de evaluación y corrección dinámica es metodológicamente similar a la función de validación que ejercerá el orquestador propuesto en este trabajo. La investigación de Yan confirma que la inclusión de bucles de retroalimentación (feedback loops) dentro del flujo de inferencia es una práctica consolidada y necesaria para robustecer los sistemas ante datos ambiguos, lo cual en nuestra arquitectura sirve además para forzar la reactivación del Sistema 2 del experto humano.

En el ámbito de la adaptación a dominios específicos, la metodología utilizada por (Sun et al., 2024) comparte la premisa de la segmentación de índices y la recuperación híbrida. Para resolver la especificidad terminológica en sus casos de estudio, los autores optaron por una arquitectura que combina búsquedas de palabras clave con embeddings densos ajustados al dominio. Esta elección respalda la decisión de este proyecto de implementar estrategias de vectorización diferenciadas para cada silo de información, en lugar de aplicar una estrategia uniforme que diluya la semántica técnica.

Finalmente, (Gao et al., 2024), en su sistematización del Modular RAG, describen metodologías que integran explícitamente módulos de re-ranking y reescritura de consultas. La arquitectura propuesta adopta estos componentes al diseñar el orquestador no solo como un enrutador, sino como un reescritor de prompts que adapta la consulta del usuario al lenguaje técnico del módulo destino. La convergencia de estas metodologías en la literatura reciente confirma que el diseño de un Sistema Multi-RAG con Orquestación Reflexiva no es una apuesta experimental, sino la aplicación de un paradigma de ingeniería validado para superar las limitaciones de escalabilidad operativa y cognitiva.

# Informe de valor ético y social

## Autoevaluación del impacto y contribución

El presente trabajo de investigación, centrado en el diseño de una arquitectura Multi-RAG con Orquestación Reflexiva, trasciende la innovación tecnológica para constituirse en un aporte sustancial a la integridad epistémica en la gestión del conocimiento corporativo. Desde una perspectiva social y organizacional, la propuesta contribuye activamente al bien común al proponer mecanismos de transparencia técnica y trazabilidad aplicables a entidades del Sector Energético, un dominio de alta criticidad para el desarrollo nacional. Al facilitar el acceso preciso a normativas regulatorias (ENRE, CAMMESA) y datos técnicos, el sistema promueve una cultura de gestión basada en la evidencia, reduciendo asimetrías de información y mejorando la eficiencia en la prestación de servicios públicos esenciales.

En términos de desarrollo humano y sustentabilidad, el proyecto se adhiere al paradigma de Inteligencia Aumentada (Augmented Intelligence). La arquitectura no persigue el desplazamiento del operador humano, sino su potenciación mediante un enfoque de Human-in-the-loop. Éticamente, esto implica preservar la agencia humana, liberando a ingenieros y analistas de la búsqueda documental rutinaria, pero introduciendo mecanismos estratégicos que previenen la "entrega cognitiva" (cognitive surrender). De este modo, el sistema protege la autonomía epistémica del profesional, forzándolo a ejercer su juicio crítico en decisiones estratégicas de infraestructura y regulación en lugar de depender acríticamente del algoritmo. Asimismo, la optimización digital favorece la sustentabilidad operativa mediante la desmaterialización de procesos.

Desde la óptica de la competencia ética profesional, el diseño prioriza la mitigación de alucinaciones como un imperativo moral, alineándose con el valor de la búsqueda de la verdad del ideario de la Universidad Austral. Al segmentar bases vectoriales, se reduce el riesgo de generar información técnica espuria. Complementariamente, el sistema integra Privacidad desde el Diseño: dado que se utilizan fuentes públicas para la instrucción del modelo y datos sintéticos para simular información confidencial, se garantiza la protección de secretos industriales y datos sensibles, demostrando un manejo responsable de la información.

## Declaración sobre aspectos éticos cuestionables

Se declara que el proyecto no presenta aspectos éticos cuestionables que requieran un Informe de Discernimiento Ético adicional. Los riesgos inherentes al uso de IA Generativa, tales como el sesgo o la fuga de datos, han sido neutralizados metodológicamente mediante el uso prioritario de documentación de dominio público (Boletín Oficial, Balances CNV) y la generación de datos sintéticos (mock data) para las pruebas de concepto, asegurando el estricto cumplimiento de las normativas de protección de datos personales y ética en la ingeniería.

## 7. Metodología

### **Metodología y técnicas para utilizar:**

El desarrollo del presente Trabajo Final se enmarca en un enfoque de investigación aplicada con diseño experimental. La estrategia metodológica consiste en la construcción de un prototipo de software (artefacto) para someterlo a pruebas de rendimiento en un entorno controlado, contrastando su eficacia frente a métodos tradicionales. El proceso se estructurará siguiendo lineamientos de metodologías estándar para ciencia de datos (como CRISP-DM u homólogas), adaptadas a proyectos de investigación académica que integran evaluación algorítmica y seguridad cognitiva.

### **Tipo de estudio:**

Se define como un estudio de alcance correlacional y explicativo, con un diseño cuasi-experimental de corte transversal.

- Es aplicado porque busca resolver la problemática concreta de fragmentación informativa y dependencia algorítmica en entornos corporativos de alta complejidad regulatoria y técnica como lo es el Sector Energético.
- Es explicativo porque busca demostrar por qué la orquestación modular mejora la precisión semántica al procesar dominios heterogéneos y cómo la introducción de fricción estratégica preserva el juicio crítico.
- Es cuasi-experimental debido a que se manipularán variables intencionalmente (la arquitectura del sistema: Baseline Monolítico vs. Multi-RAG Reflexivo) para observar su efecto en las métricas de recuperación y orquestación, utilizando un corpus documental seleccionado estratégicamente.

### **Emplazamiento:**

El desarrollo y validación del prototipo se simulará en el contexto operativo de una Empresa del Sector Energético (Generación, Transporte y/o Distribución), replicando los requerimientos de información de gerencias críticas tales como: Regulatoria y Legal (Normativas y Contratos), Administración y Finanzas (Balances y Control de Gestión), e Impuestos, entre otras áreas de soporte corporativo. Las pruebas se ejecutarán en un entorno de laboratorio (sandbox) diseñado para emular esta infraestructura de gestión documental multidominio.

### **Población, criterios de inclusión/exclusión:**

La unidad de análisis está constituida por el corpus documental técnico-administrativo del dominio energético. Para fines de esta investigación, se conformará un corpus piloto representativo (estimado en un rango de 300 a 500 documentos, sujeto a disponibilidad y relevancia semántica) que permita validar estadísticamente las métricas de desempeño.

- **Criterios de inclusión:** Contemplan una estrategia híbrida. Se integrarán fuentes públicas de índole regulatoria, legal e impositiva (Resoluciones ENRE/ENARGAS, Procedimientos CAMMESA, Leyes del Marco Regulatorio, Pliegos RenovAr/MATER y normativas tributarias). Asimismo, se incluirán fuentes contables-financieras públicas (Estados Financieros, Memorias y

Reseñas de empresas de oferta pública). Para representar documentación interna confidencial, se incorporarán fuentes simuladas (generadas sintéticamente o anonimizadas) incluyendo modelos de Contratos PPA, informes de gestión y reportes de auditoría.

- **Criterios de exclusión:** Se descartarán documentos ilegibles (manuscritos o imágenes sin OCR viable) o planos técnicos complejos que excedan el alcance del procesamiento de visión artificial (*Visual Document Understanding*) propuesto.

### **Variables:**

- **Variable Independiente:** Arquitectura del Sistema (Niveles: RAG Monolítico Genérico vs. Multi-RAG con Orquestación Reflexiva).
- **Variables Dependientes (Rendimiento Algorítmico):** Métricas estandarizadas de recuperación y generación, tales como Precisión de Contexto (Context Precision), Fidelidad (Faithfulness) y Latencia.
- **Variables Dependientes (Seguridad Cognitiva):** Métricas de comportamiento del orquestador, específicamente la "Tasa de Activación de la Zona Gris" (frecuencia con la que el sistema deniega una respuesta directa para forzar la Ruta Reflexiva y evitar la entrega cognitiva del usuario) y la Precisión de Enrutamiento (*Routing Accuracy*).

### **Métodos y técnicas de recogida de datos:**

Para la recolección y validación se utilizará un enfoque técnico-cuantitativo:

- **Ingeniería de Datos:** Recolección y normalización de normativas y balances desde fuentes oficiales; y generación de datos sintéticos verosímiles mediante LLMs para suplir documentos confidenciales.
- **Evaluación Automatizada:** Utilización de marcos de evaluación estandarizados (como RAGAS o similares) para generar un Golden Dataset de pares pregunta-respuesta. Esto permite medir métricas cuantitativas de forma escalable y reproducible, prescindiendo de la subjetividad de evaluadores humanos en esta etapa de validación de la arquitectura.

### **Análisis de datos:**

Se realizará un análisis cuantitativo comparando estadísticamente las métricas de desempeño clave del modelo propuesto frente al baseline (RAG Monolítico). Se evaluará la precisión, el recall y la fidelidad fáctica. Críticamente, se analizará la tasa de activación de la zona gris como el proxy cuantitativo que demuestra la capacidad del sistema para operar como un Sistema 3, introduciendo fricción cuando la incertidumbre semántica lo requiere. Complementariamente, se llevará a cabo un análisis cualitativo sobre los patrones de error y alucinaciones detectados (incluyendo casos atípicos o edge cases), para identificar desafíos semánticos específicos del dominio energético.

### **Ética:**

Se priorizará el uso de fuentes de dominio público para eliminar riesgos de confidencialidad empresarial y propiedad intelectual. Para los documentos sintéticos o internos simulados, se aplicarán estrictas técnicas de Data Masking y anonimización, garantizando el cumplimiento de las normativas de protección de datos personales vigentes.

### **Limitaciones del estudio:**

Los resultados estarán condicionados por la representatividad del corpus público, lo que podría limitar la evaluación de procesos internos altamente específicos o de secreto industrial. Asimismo, las restricciones de hardware académico podrían condicionar el uso de los modelos de lenguaje más masivos, optando por versiones optimizadas (estrategia de Tiering de modelos) que equilibren la capacidad de razonamiento con el costo computacional.

## Referencias

- Alanazi, M., Soh, B., Samra, H., & Li, A. (2025). The Influence of Artificial Intelligence Tools on Learning Outcomes in Computer Programming: A Systematic Review and Meta-Analysis. *Computers*, 14(5), 185.  
<https://doi.org/10.3390/computers14050185>
- Anthropic. (2024). Model Context Protocol (MCP) Introduction and Documentation. Anthropic Open Source. <https://modelcontextprotocol.io/docs/getting-started/intro>
- Asai, A., Wu, Z., Wang, Y., Sil, A., & Hajishirzi, H. (2023). *Self-RAG: Learning to retrieve, generate, and critique through self-reflection*. arXiv.  
<https://arxiv.org/abs/2310.11511>
- Barnett, S., Kurniawan, S., Thudumu, S., Brannelly, Z., & Abdelrazek, M. (2024). *Seven failure points when engineering a retrieval augmented generation system*. arXiv. <https://arxiv.org/abs/2401.05856>
- Gao, Y., Xiong, Y., Wang, M., & Wang, H. (2024). *Modular RAG: Transforming RAG systems into LEGO-like reconfigurable frameworks*. arXiv.  
<https://arxiv.org/abs/2407.21059>
- Gazzaniga, M. S. (2015). *Relatos desde los dos lados del cerebro: Una vida dedicada a la neurociencia*. Paidós.
- Kahneman, D. (2011). *Pensar rápido, pensar despacio*. Debate.
- Karpukhin, V., Oğuz, B., Min, S., Lewis, P., Wu, L., Edunov, S., ... & Yih, W. T. (2020). *Dense passage retrieval for open-domain question answering*. arXiv.  
<https://arxiv.org/abs/2004.04906>
- Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., ... & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33, 9459–9474.
- Liu, H., Li, C., Wu, Q., & Lee, Y. J. (2023). Visual instruction tuning. *Advances in Neural Information Processing Systems*, 36, 34892–34916.
- Liu, N. F., Lin, K., Hewitt, J., Paranjape, A., Bevilacqua, M., Petroni, F., & Liang, P. (2023). *Lost in the middle: How language models use long contexts*. arXiv.  
<https://arxiv.org/abs/2307.03172>
- Mitra, B., & Craswell, N. (2018). An introduction to neural information retrieval. *Foundations and Trends® in Information Retrieval*, 13(1), 1–126.  
<https://doi.org/10.1561/15000000061>
- Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C., Mishkin, P., ... & Lowe, R. (2022). Training language models to follow instructions with human feedback. *Advances in Neural Information Processing Systems*, 35, 27730–27744.

- Sarathi, P., Abdullah, S., Tuli, A., Khanna, S., Goldie, A., & Manning, C. D. (2024). *RAPTOR: Recursive abstractive processing for tree-organized retrieval*. arXiv. <https://arxiv.org/abs/2401.18059>
- Schick, T., Dwivedi-Yu, J., Dessì, R., Raileanu, R., Lomeli, M., Zettlemoyer, L., ... & Scialom, T. (2023). *Toolformer: Language models can teach themselves to use tools*. arXiv. <https://arxiv.org/abs/2302.04761>
- Shaw, J., & Nave, C. (2026). *The Tri-System Theory of cognition: Reimagining human-AI interaction and cognitive surrender*. SSRN. <https://doi.org/10.2139/ssrn.6097646>
- Shen, J. H., & Tamkin, A. (2026). How AI impacts skill formation. arXiv preprint arXiv:2601.20245. <https://arxiv.org/abs/2601.20245>
- Singh, A., Ehtesham, A., Kumar, S., & Khoei, T. T. (2025). *Agentic retrieval-augmented generation: A survey on agentic RAG*. arXiv. <https://arxiv.org/abs/2501.09136>
- Sun, H., Wang, Y., & Zhang, S. (2024). *Retrieval-augmented generation for domain-specific question answering: A case study on Pittsburgh and CMU*. arXiv. <https://arxiv.org/abs/2411.13691>
- Tonmoy, S. M. T. I., Zaman, S. M. M., Jain, V., Rani, A., Rawte, V., Chadha, A., & Das, A. (2024). *A comprehensive survey of hallucination mitigation techniques in large language models*. arXiv. <https://arxiv.org/abs/2401.01313>
- Wu, Q., Bansal, G., Zhang, J., Wu, Y., Li, B., Zhu, E., ... & Wang, C. (2023). *AutoGen: Enabling next-gen LLM applications via multi-agent conversation*. arXiv. <https://arxiv.org/abs/2308.08155>
- Wu, S., Xiong, Y., Cui, Y., Wu, H., Chen, C., Yuan, Y., ... & Liu, X. (2024). *Retrieval-augmented generation for natural language processing: A survey*. arXiv. <https://arxiv.org/abs/2407.13193>
- Wu, W., Li, B., Wang, H., & Liang, L. (2025). *MultiRAG: A knowledge-guided framework for mitigating hallucination in multi-source retrieval augmented generation*. arXiv. <https://arxiv.org/abs/2508.03553>
- Yan, S., Gu, J., Zhu, Y., & Ling, Z. (2024). *Corrective retrieval augmented generation*. arXiv. <https://arxiv.org/abs/2401.15884>